# 睁一只眼闭一只眼？探索多模态 LLMs 的视觉不足

童圣邦[1] 刘壮[2] 翟月翔[3]
马毅[3] 莱坤·扬[1] 谢三宁[1]

[1] 纽约大学 [2]Meta FAIR [3] 加州伯克利分校




Figure 1. 系统地识别了 GPT-4V [41] 在视觉问答（VQA）能力上的不足之处 (访问日期：2023 年 11 月 04 日)。我们的研究突出了高级系统如 GPT-4V 在处理看似简单的问题时由于不准确的视觉定位而遇到困难的情景。用**红色**表示错误的回答，而用**绿色**表示对错误答案的虚构解释。所有引用的图像均来自 ImageNet-1K 和 LAION-Aesthetic 数据集。

## Abstract

视觉足够好用于语言吗？最近多模态模型的进步主要源于大型语言模型（LLM）的强大推理能力。然而，视觉组件通常仅依赖于实例级对比语言图像预训练（CLIP）。我们的研究表明，近期多模态 LLM（MLLM）中的视觉能力仍然存在系统性不足。为了理解这些错误的根本原因，我们探讨了 CLIP 的视觉嵌入空间与纯粹基于视觉的自监督学习之间的差距。我们识别出“CLIP 盲对”——尽管有明显的视觉差异，但 CLIP 认为相似的图像。利用这些对，我们构建了多模态视觉模式（MMVP）基准测试。MMVP 揭示了最先进的系统，包括 GPT-4V，在九种基本视觉模式上的简单问题上遇到困难，并经常给出不正确的答案和虚构的解释。我们进一步评估了各种基于 CLIP 的视觉和语言模型，并发现挑战 CLIP 模型的视觉模式与那些困扰多模态 LLM 的问题之间存在显著相关性。作为解决这些问题的初步努力，我们提出了一种特征混合（MoF）方法，证明将视觉自监督学习特征与 MLLM 结合可以显著提高其视觉定位能力。总的来说，我们的研究建议视觉表示学习仍然是一个开放的挑战，准确的视觉定位对于未来成功的多模态系统至关重要。

## 1. 介绍

多模态大型语言模型（MLLMs）[8, 13, 31, 40] 近年来发展迅速。MLLMs 将图像整合进大型语言模型（LLMs），并利用了 LLMs 的强大能力 [41, 59, 69]，在诸如图像理解、视觉问答和指令跟随等任务上表现出色。特别是最近发布的 GPT-4V(ision) [40] 已经将性能提升到了前所未有的水平 [41, 63]。

然而，在这些模型的进步背后，我们发现存在一个显

著的弱点：它们仍然存在一些视觉上的不足，其中有些问题相当基础且明显（见图 1）。我们问：这些问题源自何处？是视觉模式的问题，还是语言理解的问题，或者两者的对齐问题？在这项工作中，我们认为在 MLLMs 中观察到的这些不足可能源于与 **视觉表示**相关的问题。

在核心层面，大多数多模态语言模型（MLLMs）[8, 31, 71] 基于预训练的视觉 [43, 54] 和语言 [59, 68, 69] 模型构建。这些模型通过各种类型的适配器 [2, 26, 31] 连接起来以整合不同的模态。一个自然的假设是，预训练视觉模型中的任何限制都可能传递给采用它们的下游 MLLMs。研究已经探讨了类似的语言问题。例如，Tong et al. [57], Yuksekgonul et al. [65] 表明，预训练文本编码器 [43, 44] 中的失败模式会导致基于文本引导的生成模型 [22, 46] 的下游失败。

在视觉方面，大多数开源 MLLMs [2, 26, 31] 采用了预训练的对比语言-图像预训练（CLIP）模型 [43] 作为视觉编码器。我们首先识别出 CLIP 难以正确编码的失败示例（第 2节）。受 Tong et al. [57] 启发，我们利用嵌入空间中的错误一致。如果两个视觉上不同的图像被 CLIP 编码得相似，则至少有一张图像是模糊地编码的。我们将这样的图像对称为 CLIP 盲对。为了测量图像之间的视觉相似性，我们使用仅限视觉的自监督编码器，如 DINOv2 [42]。在这种情况下，CLIP 盲对是指具有相似 CLIP 嵌入但不同 DINOv2 嵌入的图像。

我们发现这些 CLIP 盲对确实会导致下游 MLLM 出现错误。通过这些对，我们引入了 MultiModal Visual Patterns (MMVP) 基准测试。该基准测试专门设计用于询问 CLIP 盲对之间的差异，并用简单的问题评估最先进的 MLLM 的视觉能力。我们评估了各种开源模型 [8, 30, 31, 71] 和闭源模型 [13, 41] 包括 GPT-4V [40]，并进行了一项用户研究以测量人类的表现。结果显示，MLLM 模型在处理直接的视觉问题上存在困难。大多数模型的表现低于随机猜测水平，而 GPT-4V 是例外。然而，即使对于 GPT-4V 来说，其表现也与人类相比有显著差距——超过 50%。

识别出 MLLM 中的大量个别失败实例后，我们继续研究 MMVP 中的系统性视觉模式，这些模式使得 CLIP 模型难以应对（第 3节）。我们在 MMVP 中总结了九种常见的 CLIP 盲对模式，如“方向”、“计数”和“视角”，这些都给 CLIP 视觉编码器带来了重大挑战。需要注意的是，在扩展训练数据和模型规模方面，CLIP 已经有了显著且持续的进步 [10, 43, 54, 62, 66]。我们将来自 MMVP 的例子归类为视觉模式，以系统地评估单纯扩大规模是否可以缓解这些挑战。我们的研究表明，9 个已识别的视觉模式中有 7 个无法被任何大规模的基于 CLIP 的模型解决，这表明单靠模型/数据扩增是不够的。此外，我们还发现了挑战 CLIP 模型的视觉模式与 MLLM 性能之间存在强烈的相关性。如果 CLIP 在一个特定的视觉模式上遇到困难，例如“方向”，那么 MLLM 也很可能表现不佳。这表明 CLIP 视觉编码器可能会成为此类系统的瓶颈。

最后，我们朝着改进多模态语言模型（MLLMs）的视觉定位能力迈出了一步。由于 MLLMs 的视觉缺陷源于其对 CLIP 模型的依赖，我们在第4节探讨了将以视觉为中心的表示整合进 MLLMs 的影响。具体来说，我们研究了如何结合一个仅基于视觉的自监督模型，如 DINOv2 [42]，来增强 MLLMs 的视觉定位能力。我们将这些技术称为特征混合（Mixture-of-Features，简称 MoF）。首先，我们按不同比例线性地混合 CLIP 和 DINOv2 的特征，这被称为加法特征混合（Additive-MoF，简称 A-MoF）。这一过程揭示了 DINOv2 的特征在视觉定位上更为有效，尽管它们会降低指令跟随的能力。为了解决这个问题，我们引入了交错特征混合 (Interleaved-MoF，简称 I-MoF)，该方法在空间上混合来自 CLIP 和 DINOv2 模型的视觉标记。我们发现这种方法显著增强了视觉定位能力，同时保持了指令跟随的能力。

## 2. 多模态视觉模式（MMVP）基准测试

目前，大多数开源 MLLMs [8, 31, 71] 使用现成的 CLIP 视觉编码器来处理图像。在本节中，我们首先识别 CLIP 模型中的 CLIP 盲对（第2.1节）。随后，我们利用这些 CLIP 盲对构建多模态视觉模式-MLLM（MMVP-MLLM）基准测试（第2.2节）。我们在该基准上评估 SOTA MLLMs，包括 GPT-4V（第2.3节），并发现所有测试模型在简单的问题上都难以应对视觉细节。这一过程的可视化如图 2所示。

### 2.1. 寻找 CLIP 盲对

直接找到 CLIP 视觉编码器难以“正确”编码的实例 (图像) 是具有挑战性的。为了解决这个问题，我们扩展了 Tong et al. [57] 提出的想法，自动在视觉模型中查找盲对。其基本原理很简单：如果有两张尽管外观差异显著但被 CLIP 视觉编码器相似编码的图片，则其中一张很可能是模糊编码的（参见图 2 左侧示例）。为了衡量两张图片之间的视觉差异，我们在一个参考模型中检查这些图片的表示形式：这是一个无需任何语言指导训练的纯视觉自监督模型，例如 DINOv2 [42]。这些模型已被证明能够捕捉更多的视觉细节和信息 [42, 53]。

我们使用语料库数据集 ImageNet [47] 和 LAION-Aesthetics [48] 来收集这些 CLIP 盲对。

对于每一对图片，我们使用 CLIP-ViT-L-14 [9, 43] 模型计算它们的 CLIP 嵌入，并使用 DINOv2-ViT-L-14 [9, 42] 模型计算它们的 DINOv2 嵌入。我们返回那些 CLIP 嵌入余弦相似度超过 0.95 且 DINOv2 嵌入余弦相似度小于 0.6 的图片对。

### 2.2. 基于 CLIP 盲对的设计基准

我们引入了多模态视觉模式 (MMVP) 基准测试，并设计了一个视觉问题回答 (VQA) 基准测试。利用收集到的 CLIP 盲对，我们精心设计了包含 150 对图像和 300 个问题的数据集。对于每一对 CLIP 盲对图像，我们手动指出了 CLIP 视觉编码器忽略的视觉细节（见图 2中间部分），并设计出能够探测这些视觉细节的问题，例如“狗是面向左边还是右边?”（见图 2右侧及更多示例在图 3）。主要目标是确定当面对这些问题时，MLLM

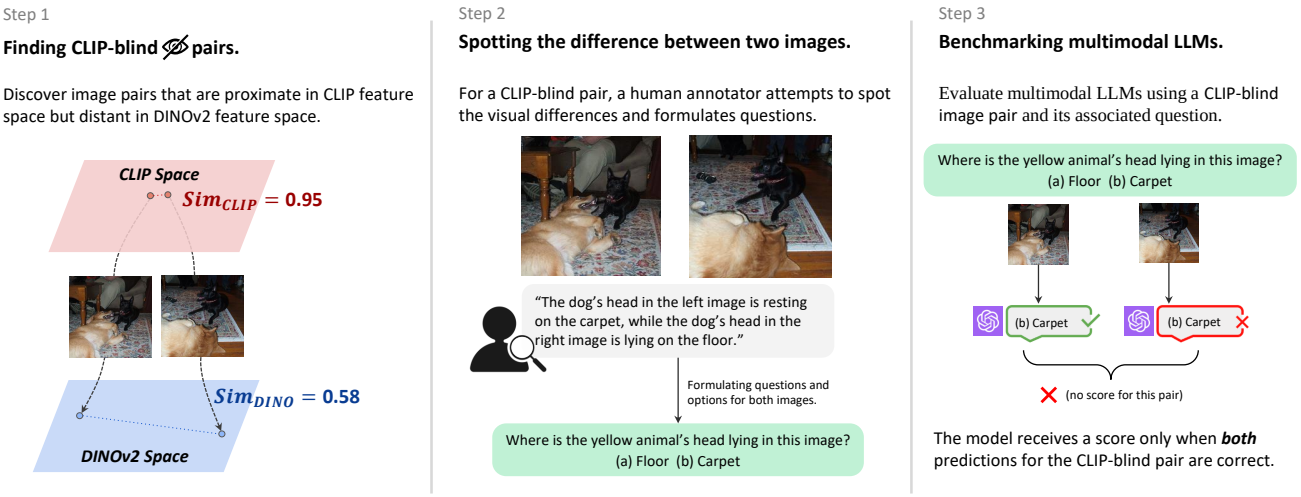



Figure 2. 通过 CLIP 盲对构建 MMVP 基准。**左：**我们首先找到具有相似 CLIP 嵌入但不同 DINOv2 嵌入的 CLIP 盲对。**中间：**我们手动检查每对图像之间的差异，并根据图像中的差异制定问题。**右：**我们向 MLLMs 提出这些问题以及 CLIP 盲对。只有当模型正确回答了 CLIP 盲对的所有问题时，它才会获得分数。

模型是否会失败并忽略关键的视觉细节。因此，这些问题被故意设计得简单明了。

### 2.3. 基准测试结果

我们评估了在 SOTA 开源模型（LLaVA-1.5 [31], InstructBLIP [8], Mini-GPT4 [71]）和闭源模型（GPT-4V [40], Gemini [14], Bard [13]）上的问题。关于如何访问这些模型的具体细节见附录 B.1。在我们的评估中，每个问题是独立查询的，以消除聊天历史记录带来的任何偏见。我们也通过用户研究来评估人类的表现，在该研究中，用户会随机顺序地看到 300 个问题。对于任意一对图像，我们认为这对图像是正确回答的，当且仅当与这对图像相关联的问题都被准确回答。

**人类研究证实问题很简单。** 如图 4所示，人类参与者平均准确回答了 95.7% 的问题。这一高准确率强调了问题的简单性。更多细节见附录 B.5。

**当前的多模态语言模型在视觉细节上存在困难。** 如图 4所示，尽管后者经常表现出令人印象深刻的结果 [6, 27]，人类和多模态语言模型之间仍存在显著性能差距。除了 GPT-4V 和 Gemini 外，其他模型得分低于随机猜测水平（25%）。最先进的 GPT-4V 和 Gemini 也面临解决基本视觉定位问题的挑战。图 1和 3提供了模型错误的例子。结果表明，无论模型大小或训练数据如何，它们都难以处理视觉细节。

我们还进行了一项消融研究，例如交换选项和改变问题表述中的标记（详见附录 B.4），以进一步确认这种表现不佳源于视觉能力不足，而不是语言模型中的幻觉现象。

## 3. CLIP 中的系统性故障

在上一节中，我们识别了 CLIP 盲对，并使用它们来发现 MLLMs 中的故障。在这里，我们将深入研究这些对，以调查 (i) 从 CLIP 盲对中出现的系统性视觉模式（第3.1节），(ii) 这些视觉模式是否对大规模扩展的基于 CLIP 的模型构成挑战（第3.2节），以及 (iii) CLIP 模型中的故障模式与 MLLMs 中的故障模式之间的相关性（第3.3节）。

### 3.1. CLIP 盲对中的视觉模式

已经识别出 CLIP 盲对后，我们总结了 CLIP 视觉编码器可能一致误解的系统性视觉模式。直接捕捉 CLIP 盲对中的系统性视觉模式过于抽象。因此，我们转向 MMVP 基准的问题和选项。通过这些问题，我们将图像中的抽象视觉模式转化为更清晰的语言描述符，使其更容易分类。

在这项工作中，我们使用 GPT-4 [41] 通过以下提示对其进行分类：

**用户**

我正在分析一个图像嵌入模型。你能浏览一下问题和选项，尝试找出一些嵌入模型难以处理的一般模式吗？请专注于视觉特征并概括对视觉模型重要的模式。
[MMVP 问题和选项]

我们识别出 9 种视觉模式：

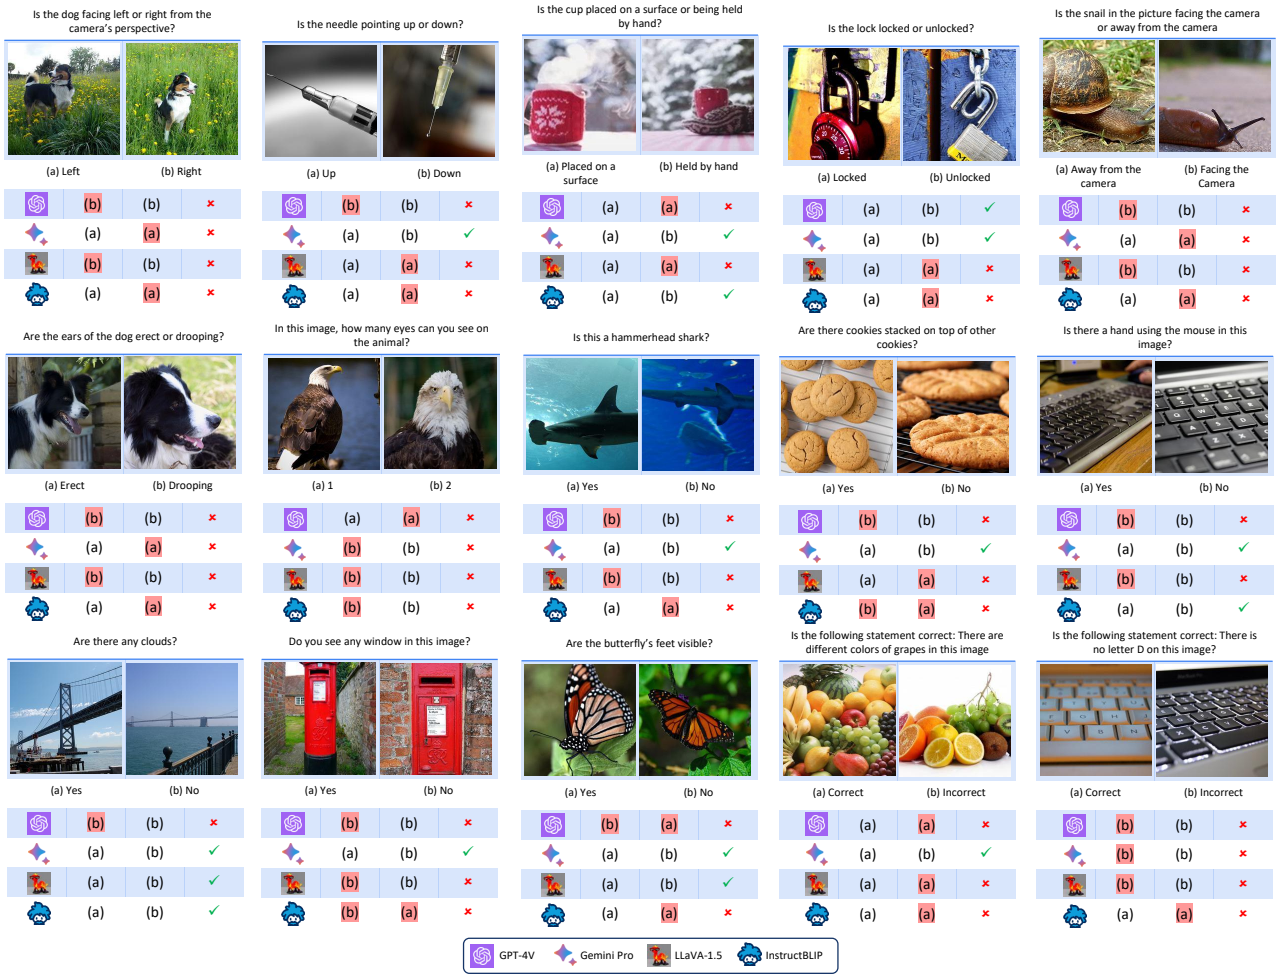



Figure 3. MMVP **基准测试中的问题示例。**错误答案用红色标注。只有当一个模型正确回答了一对问题中的两个问题时，才被认为是正确的。无论是领先的闭源模型（GPT-4V，Gemini）还是开源模型（LLaVA-1.5，InstructBLIP）都未能通过这些简单的视觉问题。（详见附录 B.2中的 MMVP 基准测试的所有问题。）

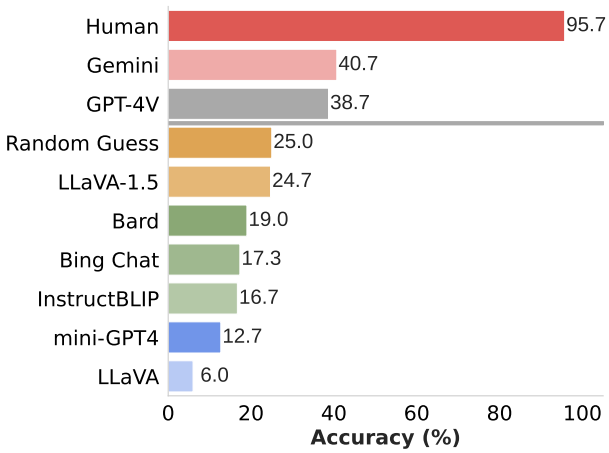



Figure 4. **当前** SOTA **多模态语言模型和人类的基准测试结果。**我们通过用户研究对当前 SOTA 多模态语言模型和人类表现进行了基准测试问题的评估。

- Orientation and Direction
- Presence of Specific Features
- State and Condition
- Quantity and Count
- Positional and Relational Context
- Color and Appearance
- Structural and Physical Characteristics
- Text
- Viewpoint and Perspective

这些视觉模式表明 CLIP 视觉编码器过于侧重于高层次的语义理解，忽视了视觉世界的复杂细节。完整的视觉模式描述可以在附录 D中找到。

### 3.2. MMVP-VLM 基准测试

基于 CLIP 的模型自首次引入以来发展迅速 [43]。我们想测试这些视觉模式是否仍然对最近的 CLIP 模型构成挑战 [10, 54, 62, 66]，这些模型在训练数据量和模型规模上有了显著提升。为此，我们引入了一个新的基

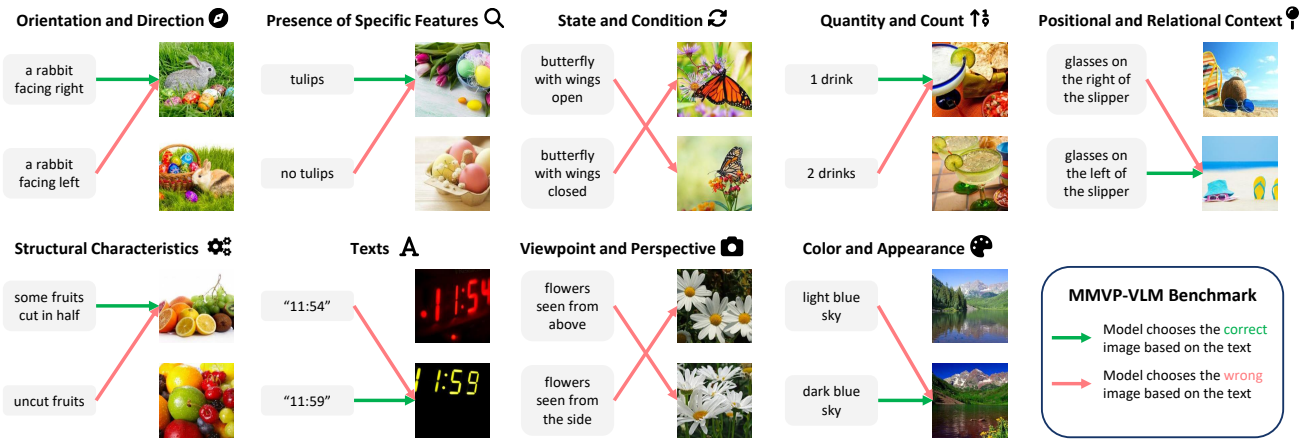



Figure 5. MMVP-VLM **的示例。** MMVP-VLM 包含跨越九种视觉模式的图像对。图中的示例来自 EVA01 ViT-g-14 模型 [54]，这是最大的 CLIP 模型之一，也未能根据文本描述选择正确的图像。

| | Image Size | Params (M) | IN-1k ZeroShot | | | | | | | | | | MMVP Average |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| OpenAI ViT-L-14 [43] | $224^2$ | 427.6 | 75.5 | 13.3 | 13.3 | 20.0 | 20.0 | 13.3 | 53.3 | 20.0 | 6.7 | 13.3 | 19.3 |
| OpenAI ViT-L-14 [43] | $336^2$ | 427.9 | 76.6 | 0.0 | 20.0 | 40.0 | 20.0 | 6.7 | 20.0 | 33.3 | 6.7 | 33.3 | 20.0 |
| SigLIP ViT-SO-14 [66] | $224^2$ | 877.4 | 82.0 | 26.7 | 20.0 | 53.3 | 40.0 | 20.0 | 66.7 | 40.0 | 20.0 | 53.3 | 37.8 |
| SigLIP ViT-SO-14 [66] | $384^2$ | 878.0 | 83.1 | 20.0 | 26.7 | 60.0 | 33.3 | 13.3 | 66.7 | 33.3 | 26.7 | 53.3 | 37.0 |
| DFN ViT-H-14 [10] | $224^2$ | 986.1 | 83.4 | 20.0 | 26.7 | 73.3 | 26.7 | 26.7 | 66.7 | 46.7 | 13.3 | 53.3 | 39.3 |
| DFN ViT-H-14 [10] | $378^2$ | 986.7 | 84.4 | 13.3 | 20.0 | 53.3 | 33.3 | 26.7 | 66.7 | 40.0 | 20.0 | 40.0 | 34.8 |
| MetaCLIP ViT-L-14 [62] | $224^2$ | 427.6 | 79.2 | 13.3 | 6.7 | 66.7 | 6.7 | 33.3 | 46.7 | 20.0 | 6.7 | 13.3 | 23.7 |
| MetaCLIP ViT-H-14 [62] | $224^2$ | 986.1 | 80.6 | 6.7 | 13.3 | 60.0 | 13.3 | 6.7 | 53.3 | 26.7 | 13.3 | 33.3 | 25.2 |
| EVA01 ViT-g-14 [54] | $224^2$ | 1136.4 | 78.5 | 6.7 | 26.7 | 40.0 | 6.7 | 13.3 | 66.7 | 13.3 | 13.3 | 20.0 | 23.0 |
| EVA02 ViT-bigE-14+ [54] | $224^2$ | 5044.9 | 82.0 | 13.3 | 20.0 | 66.7 | 26.7 | 26.7 | 66.7 | 26.7 | 20.0 | 33.3 | 33.3 |

Table 1. MMVP-VLM 基准测试中基于 CLIP 的各种模型在不同视觉模式上的性能表现。分辨率提升的模型（放大分辨率）几乎没有改进，而当网络规模扩大时（扩展网络），则观察到了轻微的优势。对于每个视觉模式，我们使用浅灰色突出显示最佳性能。大多数视觉模式下，所有基于 CLIP 的方法都表现出困难，这可以从得分中看出。由于空间限制，我们用符号表示视觉模式：🧭：方向和方位，🔍：特定特征的存在，🔄：状态和条件，🔢：数量和计数，📍：位置和关系上下文，🎨：颜色和外观，⚙️：结构和物理特性，🅰️：文本，📷：视点和视角。

准：MMVP-VLM，以系统地研究 CLIP 模型是否能很好地处理这种视觉模式。

我们将 MMVP 基准的一部分问题提炼为更简单的语言描述，并将其分类为不同的视觉模式。为了保持每个视觉模式的问题数量平衡，如有必要，我们会添加一些问题，以确保每个视觉模式都有 15 个图文配对。图 5展示了配对示例。如果模型能够准确匹配图像和文本组合，则认为该配对被正确回答。

我们在多种 CLIP 模型上评估了 MMVP-VLM [10, 43, 54, 62, 66]。这些模型在大小、训练数据和方法论等方面有所不同。如表 1所示，网络规模和训练数据的增加仅有助于识别两种视觉模式——“颜色和外观”以及“状态和条件”。其余的视觉模式继续对所有基于 CLIP 的模型构成挑战。我们还发现，ImageNet-1k 零样本准确性并不是衡量模型在视觉模式方面性能的确切指标。这强调了需要额外的评估指标（例如 MMVP-VLM）来准确评估模型在图像分类之外领域的功能。

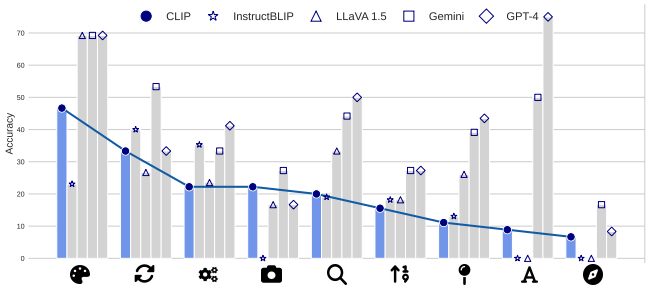



Figure 6. CLIP **和** MLLM **在视觉模式上的表现。**如果 CLIP 在某个视觉模式上表现不佳，例如“🧭 方向性”，那么 MLLM 在该视觉模式上也会表现不佳。

### 3.3. CLIP 的错误如何影响多模态语言模型（MLLMs）

在分析了 CLIP 模型难以处理的视觉模式后，我们提出了以下问题：CLIP 表现不佳与 MLLM 视觉能力不足之间是否存在相关性？为了探讨这一点，我们将

MMVP 中的问题归类为这些总结出的视觉模式，并计算每个 MLLM 在这些模式上的表现。

在图 6 中，我们绘制了 CLIP 和 MLLM 在每个视觉模式上的表现。当 CLIP 视觉编码器在一个特定的视觉模式上表现不佳时，MLLM 倾向于表现出类似的缺点。明确使用 CLIP 视觉编码器的开源模型，如 LLaVA 1.5 [30] 和 InstructBLIP [8] 显示出了性能上的强相关性。

进一步地，我们计算了 CLIP 模型和 MLLM 在每个视觉模式上的皮尔逊相关系数。结果显示，LLaVA 1.5 和 InstructBLIP 的相关系数均大于 0.7。这一高分表明存在强烈的关联，即 CLIP 模型在视觉模式识别方面的弱点被传递到了 MLLM 上。关于皮尔逊相关系数的更多细节可以在附录 C 中找到。

## 4. 特征混合(MoF)在多模态语言模型(MLLM)中的应用

基于我们在前面章节中的探索，一个自然的问题出现了：如果开源 MLLM 的视觉缺陷来自 CLIP 视觉编码器，我们如何构建更强大的视觉编码器？在本节中，我们将通过研究特征混合（MoF）来初步回答这个问题。我们首先采用加性 MoF，该方法混合了 CLIP 特征和仅用于视觉的自监督学习模型特征。结果显示，在 MLLM 中用作预训练模型时，每个编码器都具有独特的优势和局限性（参见第4.2节）。随后，我们提出了交错 MoF，该方法将 CLIP 和 SSL 的特征整合到 MLLM 中，以增强视觉定位能力而不影响模型遵循指令的能力（参见第??节）。

### 4.1. 实验设置

我们采用 LLaVA [30, 31] 作为研究 MLLM 中视觉编码器的框架。LLaVA 使用预训练的 CLIP 编码器并训练一个适配器来对齐视觉标记和语言标记在 LLM 中。(见图 7左侧)。我们在工作中使用 DINOv2 [42] 作为唯一的视觉自监督模型，因为它目前是最可扩展的唯一视觉模型。我们的探索包括使用两个视觉编码器：CLIP-ViT-L-14 [43] 和 DINOV2-ViT-L-14 [42]。为了确保一致且公平的比较，我们按照 LLaVA 中的相同实验设置进行模型的训练和微调。我们在附录 A中包含了额外的实验细节。

### 4.2. 加法 MoF

我们将预训练的 DINOv2 编码器加入 MLLM，并将其与 CLIP 预训练编码器混合。我们使用系数 $\alpha$ 来控制 CLIP 特征的比例，并用 $1-\alpha$ 来控制 DINOv2 特征的数量，然后线性地将它们相加（参见图 7中间部分以可视化）。

我们通过在第 2节提出的 MMVP 评估模型的视觉定位能力，并通过 Liu et al. [31]介绍的 LLaVA 基准测试评估模型的指令跟随能力。最初，我们进行了五项实验，其中线性过渡从使用 100% 的 CLIP 特征到 100% 的 DINOv2 特征。在这次测试中，DINOv2 特征比例设置为 $\{0.00, 0.25, 0.50, 0.75, 1.00\}$。为了进一步验证观察到的趋势，我们引入了两个额外的实验，其 DINOv2 比例分别为 $\{0.625, 0.875\}$。我们在表 2中呈现的研究结果揭示了两点见解：

1. 随着 DINOv2 特征比例的增加，MLLM 的指令跟随能力下降。值得注意的是，在 DINOv2 比例达到 87.5% 时出现了急剧下降。
2. 较高的 DINOv2 特征比例增强了模型的视觉定位能力，但当 DINOv2 比例超过 0.75 时，这种优势减弱，此时指令跟随能力明显受损。

Hence, if we were to add DINOv2 features or completely replace CLIP with DINOv2, it would result in a trade-off between visual grounding and instruction-following. A higher proportion of DINOv2 features improves the model's visual perception at the expense of its ability to follow linguistic instructions, while CLIP features enhance language comprehension but reduce visual grounding.

| method | SSL ratio | MMVP | LLaVA |
|---|---|---|---|
| LLaVA | 0.0 | 5.5 | 81.8 |
| LLaVA + A-MoF | 0.25 | 7.9 (+2.4) | 79.4 (-2.4) |
| | 0.5 | 12.0 (+6.5) | 78.6 (-3.2) |
| | 0.625 | 15.0 (+9.5) | 76.4 (-5.4) |
| | 0.75 | 18.7 (+13.2) | 75.8 (-6.0) |
| | 0.875 | 16.5 (+11.0) | 69.3 (-12.5) |
| | 1.0 | 13.4 (+7.9) | 68.5 (-13.3) |

Table 2. Empirical Results of Additive MoF. We use DINOv2 as the image SSL model in our work. With more DINOv2 features added, there is an improvement in visual grounding, while a decline in instruction following ability.

### 4.3. 交错 MoF

我们提出交错 MoF 以利用 CLIP 和 DINOv2 嵌入的优势来增强图像表示。一幅图像同时传递给 CLIP 和 DINOv2 编码器，并且生成的嵌入分别由适配器处理。我们将来自 CLIP 和 DINOv2 的处理后的特征进行交错，同时保持它们原有的空间顺序。然后我们将交错后的特征输入到 LLM（见图 7右侧）。

| method | res | #tokens | MMVP | LLaVA | POPE |
|---|---|---|---|---|---|
| LLaVA | $224^2$ | 256 | 5.5 | 81.8 | 50.0 |
| LLaVA | $336^2$ | 576 | 6.0 | 81.4 | 50.1 |
| LLaVA + I-MoF | $224^2$ | 512 | 16.7 (+10.7) | 82.8 | 51.0 |
| $\text{LLaVA}^{1.5}$ | $336^2$ | 576 | 24.7 | 84.7 | 85.9 |
| $\text{LLaVA}^{1.5}$ + I-MoF | $224^2$ | 512 | 28.0 (+3.3) | 82.7 | 86.3 |

Table 3. **交错 MoF 的经验结果。**交错 MoF 在维持相同指令跟随能力的同时提高了视觉定位效果。

我们在表 3中总结了实验结果。在 LLaVA 设置下，交错 MoF 显著增强了视觉定位能力，在 MMVP 中观察到了 10.7% 的增长，而不会影响模型遵循指令的能

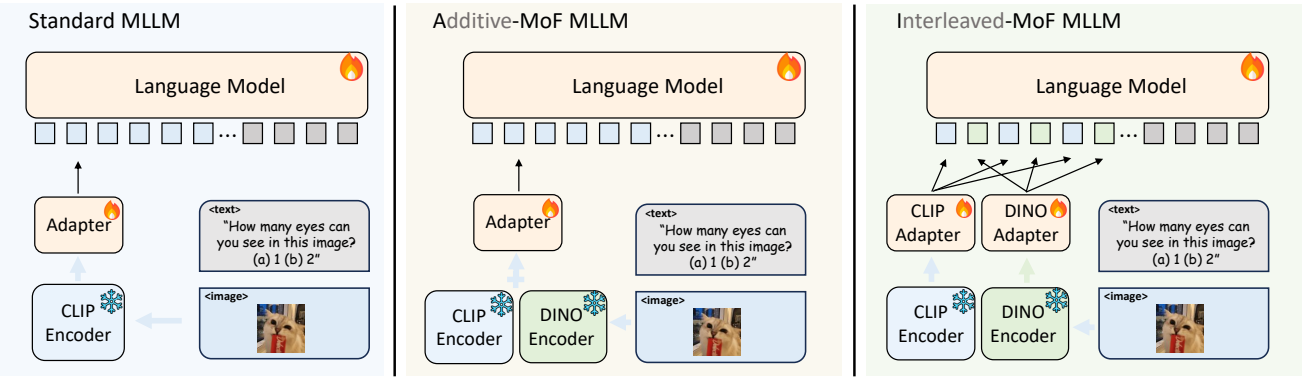



Figure 7. MLLM **中不同的特征混合（**MoF**）策略。**左图：使用 CLIP 作为预训练视觉编码器的标准 MLLM；中图：加性特征混合（A-MoF）MLLM：在线性适配器之前线性地混合 CLIP 和 DINOv2 特征；右图：交错特征混合（I-MoF MLLM）：在适配器之后空间上交错 CLIP 视觉标记和 DINOv2 视觉标记。

力。该实验也在 LLaVA-1.5 设置以及各种图像分辨率设置下进行了重复，得到了类似的性能提升。我们也使用 POPE [27] 进行了评估，该测试旨在检验视觉定位中的幻觉问题。交错 MoF 相对于原始 LLaVA 模型也显示出一致的改进。仅仅提高图像分辨率，进而增加 token 数量并不能提升视觉定位能力。相反，是在仅基于视觉的自监督学习模型和多模态语言视觉模型之间进行 MoF 交错，从而提升了视觉定位任务的表现。我们在附录 E.1中使用 MAE 或 MoCoV3 作为仅基于视觉的自监督学习模型进行了更多的 I-MoF 实验，并展示了类似地改善了视觉定位任务的效果。

我们还在其他基准测试上评估了交错 MoF，例如 MM-Bench [32] 和 GQA [21]，发现交错 MoF 在这些基准测试上的表现类似。更多关于这些基准测试的结果，请参见附录E.2。

## 5. 相关工作

**多模态 LLMs。** 我们研究了多模态 LLMs [8, 13, 30, 31, 40] 的局限性，并探索可能改进这些模型的方法。多模态 LLMs 基于预训练的大语言模型 [3, 41, 58, 59, 69] 和 CLIP 视觉编码器 [43, 54] 构建。然后，这些系统使用适配器（如 MLPs [30, 31]、Q-Former [8, 26] 和门控注意力机制 [2, 25]）将预训练的 CLIP 视觉编码器集成到 LLMs 中。最近，instructBLIP [8] 和 LLaVA-1.5 [30] 强调高质量训练数据的重要性。然而，关于视觉编码器影响的研究很少，这是我们的工作旨在通过系统研究来解决的重要空白。

**评估多模态 LLMs。**

MMVP 使用一组简单而关键的视觉问题回答（VQA）问题来评估多模态大规模语言模型（MLLM），这些问题由 CLIP 盲对构建而成。之前的基准测试如 TextVQA [52]、VQAv2 [15] 和 GQA [21] 主要集中在传统的 VQA 查询上。最近有一些工作如 MM-Vet [64]、POPE [27] 和 MM-Bench [32] 设计用于专门评估多模态 LLM，包括幻觉、推理和鲁棒性。之前的基准测试和评估表明，多模态 LLM 可能会受到幻觉的影响 [28, 29]、灾难性的遗忘 [67] 以及缺乏鲁棒性 [11]。在回顾基础方面，我们的研究揭示了即使是最先进的多模态 LLM，例如 GPT-4V [40]、Gemini [14]、Bard [30] 和 LLaVA-1.5 [30]，也无法避免在基本的视觉问题上出错。我们还发现其中一部分问题是由于视觉编码器的能力不足。

**视觉编码器。** MMVP-VLM 对各种 CLIP 变体的视觉能力进行了详细分析 [43, 54, 62, 66]。这些模型大多遵循了 Radford et al. [43]提出的方法，使用对比损失在大量图像-文本对上进行训练。它们在训练数据 [62]、训练配方 [54] 和目标函数 [66] 上有所不同。然而，我们的研究表明，所有这些 CLIP 变体在处理简单的视觉模式（如“方向”、“数量”、“特定特征的存在”等）方面都存在困难。另一条研究线专注于纯粹的自监督学习（SSL）。这一类别包括对比 SSL [5, 7, 16, 17] 和基于掩码的 SSL [4, 18, 70]。SLIP [39] 探索了 CLIP 和对比 SSL 之间的协同作用，但主要集中在标准分类任务上。事实上，评估这些视觉模型质量的一种常见做法是通过 ImageNet 上的线性探测或微调来进行 [45, 47]。尽管当前的评估方法提供了一定程度的质量评估，但我们的发现表明，这些方法正在逐渐脱离最近用例的需求。正如第4节中的 MoF 实验所示，CLIP 视觉模型和纯粹的视觉自监督学习模型学到了互补的特征。然而，单独依靠 ImageNet 上的线性探测准确度来理解多模态语言模型中的特征效用是有限的。这一观察结果表明，在视觉表示学习中需要更多样化的评估方法 [61]，以更好地适应当前和新兴的应用需求。

**嵌入模型中的歧义。** 我们的工作利用 CLIP 视觉嵌入空间内的 CLIP 盲对来生成 CLIP 模型以及随后 MLLMs 失败的例子。这一概念与之前专注于记录文本嵌入模型故障模式的研究有关 [12, 36, 55]。最近，Thrush et al. [56]、Yuksekgonul et al. [65] 和 Hsieh et al. [19] 研究了 CLIP 在处理文本查询时遇到的绑定问题，指出 CLIP 模型将文本输入视为词袋。Tong et al. [57] 考察了这对下游文本引导生成模型的影响。Tschannen et al. [60] 建议使用图像描述器作为改进属性绑定的有前途替代方案。我们的工作重点在于视觉模式。

## 6. 讨论

回到我们最初提出的问题：视觉是否足以用于语言？也许还不行，因为我们的研究表明，视觉模型可能成为多模态系统中的瓶颈。MLLMs 在简单问题上失败的原因是它们预训练的 CLIP 视觉编码器忽略了图像中的关键视觉细节，并且系统地未能识别重要的视觉模式。然而，CLIP 类型的模型仍然是目前最可扩展和广泛使用的视觉模型。与普遍认为数据和模型规模扩大可以解决一切问题的观点相反，我们的研究显示，仅仅扩大规模并不能纠正 CLIP 模型内在的缺陷。

我们的研究表明，流行的视觉表示学习模型——视觉和语言模型以及仅限于视觉的自监督学习模型——在不同方面表现出色。它们的能力差异超出了传统的基准测试，如 ImageNet 上的线性探测或零样本准确率。虽然精心设计的特征混合方法可以缓解视觉限制并利用这两种学习范式的优点，但开发新的评估指标以促进新视觉表示学习算法的发展是必要的。我们希望我们的工作能够激发对视觉模型的进一步创新。

**致谢。**我们感谢吴鹏浩、陶木子、埃里克·琼斯、迈克尔·普森卡、丹尼尔·叶、杜鲁夫·派伊、孙晨等人的有益讨论和反馈。这项工作得到了纽约大学 IT 高性能计算资源、服务和支持人员的帮助。该研究还得到英特尔、谷歌 TRC 项目、Google Cloud Research Credits 项目的资助（奖励编号为 GCP19980904），以及亚马逊 2023 秋季研究奖的支持。作者感谢 hyperbolic labs 支持部分实验。所有实验和数据分析都在纽约大学进行。

## References

[1] ShareGPT, 2023.

[2] Jean-Baptiste Alayrac, Jeff Donahue, Pauline Luc, Antoine Miech, Iain Barr, Yana Hasson, Karel Lenc, Arthur Mensch, Katherine Millican, Malcolm Reynolds, et al. Flamingo: a visual language model for few-shot learning. In NeruIPS, 2022.

[3] Rohan Anil, Andrew M Dai, Orhan Firat, Melvin Johnson, Dmitry Lepikhin, Alexandre Passos, Siamak Shakeri, Emanuel Taropa, Paige Bailey, Zhifeng Chen, et al. Palm 2 technical report. arXiv preprint arXiv:2305.10403, 2023.

[4] Mahmoud Assran, Quentin Duval, Ishan Misra, Piotr Bojanowski, Pascal Vincent, Michael Rabbat, Yann LeCun, and Nicolas Ballas. Self-supervised learning from images with a joint-embedding predictive architecture. In CVPR, 2023.

[5] Adrien Bardes, Jean Ponce, and Yann LeCun. Vicreg: Variance-invariance-covariance regularization for self-supervised learning. 2022.

[6] Sébastien Bubeck, Varun Chandrasekaran, Ronen Eldan, Johannes Gehrke, Eric Horvitz, Ece Kamar, Peter Lee, Yin Tat Lee, Yuanzhi Li, Scott Lundberg, et al. Sparks of artificial general intelligence: Early experiments with gpt-4. arXiv preprint arXiv:2303.12712, 2023.

[7] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In ICML, 2020.

[8] Wenliang Dai, Junnan Li, Dongxu Li, Anthony Meng Huat Tiong, Junqi Zhao, Weisheng Wang, Boyang Li, Pascale Fung, and Steven Hoi. Instructblip: Towards general-purpose vision-language models with instruction tuning, 2023.

[9] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In ICML, 2021.

[10] Alex Fang, Albin Madappally Jose, Amit Jain, Ludwig Schmidt, Alexander Toshev, and Vaishaal Shankar. Data filtering networks. arXiv preprint arXiv:2309.17425, 2023.

[11] Chaoyou Fu, Peixian Chen, Yunhang Shen, Yulei Qin, Mengdan Zhang, Xu Lin, Zhenyu Qiu, Wei Lin, Jinrui Yang, Xiawu Zheng, et al. Mme: A comprehensive evaluation benchmark for multimodal large language models. arXiv preprint arXiv:2306.13394, 2023.

[12] Hila Gonen and Yoav Goldberg. Lipstick on a pig: Debiasing methods cover up systematic gender biases in word embeddings but do not remove them. In NAACL, 2019.

[13] Google. Bard, 2023.

[14] Google. Gemini, 2023.

[15] Yash Goyal, Tejas Khot, Douglas Summers-Stay, Dhruv Batra, and Devi Parikh. Making the V in VQA matter: Elevating the role of image understanding in visual question answering. In CVPR, 2017.

[16] Jean-Bastien Grill, Florian Strub, Florent Altché, Corentin Tallec, Pierre Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Avila Pires, Zhaohan Guo, Mohammad Gheshlaghi Azar, et al. Bootstrap your own latent-a new approach to self-supervised learning. In NeurIPS, 2020.

[17] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning. In CVPR, 2020.

[18] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In CVPR, 2022.

[19] Cheng-Yu Hsieh, Jieyu Zhang, Zixian Ma, Aniruddha Kembhavi, and Ranjay Krishna. Sugarcrepe: Fixing hackable benchmarks for vision-language compositionality. In NeurIPS, 2023.

[20] Jennifer Hu and Roger Levy. Prompt-based methods may underestimate large language models' linguistic generalizations. In EMNLP, 2023.

[21] Drew A Hudson and Christopher D Manning. GQA: A new dataset for real-world visual reasoning and compositional question answering. In CVPR, 2019.

[22] Heewoo Jun and Alex Nichol. Shap-E: Generating conditional 3d implicit functions. arXiv preprint arXiv:2305.02463, 2023.

[23] Sahar Kazemzadeh, Vicente Ordonez, Mark Matten, and Tamara Berg. Referitgame: Referring to objects in photographs of natural scenes. In EMNLP, 2014.

[24] Ranjay Krishna, Yuke Zhu, Oliver Groth, Justin Johnson, Kenji Hata, Joshua Kravitz, Stephanie Chen, Yannis Kalantidis, Li-Jia Li, David A Shamma, et al. Visual genome: Connecting language and vision using crowdsourced dense image annotations. IJCV, 2017.

[25] Hugo Laurençon, Lucile Saulnier, Léo Tronchon, Stas Bekman, Amanpreet Singh, Anton Lozhkov, Thomas Wang, Siddharth Karamcheti, Alexander M Rush, Douwe Kiela, et al. Obelisc: An open web-scale filtered dataset of interleaved image-text documents. arXiv preprint arXiv:2306.16527, 2023.

[26] Junnan Li, Dongxu Li, Silvio Savarese, and Steven Hoi. BLIP-2: bootstrapping language-image pre-training with frozen image encoders and large language models. In ICML, 2023.

[27] Yifan Li, Yifan Du, Kun Zhou, Jinpeng Wang, Wayne Xin Zhao, and Ji-Rong Wen. Evaluating object hallucination in large vision-language models. arXiv preprint arXiv:2305.10355, 2023.

[28] Fuxiao Liu, Tianrui Guan, Zongxia Li, Lichang Chen, Yaser Yacoob, Dinesh Manocha, and Tianyi Zhou. Hallusionbench: You see what you think? or you think what you see? an image-context reasoning benchmark challenging for GPT-4V (ision), LLaVA-1.5, and other multi-modality models. arXiv preprint arXiv:2310.14566, 2023.

[29] Fuxiao Liu, Kevin Lin, Linjie Li, Jianfeng Wang, Yaser Yacoob, and Lijuan Wang. Aligning large multi-modal model with robust instruction tuning. arXiv preprint arXiv:2306.14565, 2023.

[30] Haotian Liu, Chunyuan Li, Yuheng Li, and Yong Jae Lee. Improved baselines with visual instruction tuning. arXiv preprint arXiv:2310.03744, 2023.

[31] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. 2023.

[32] Yuan Liu, Haodong Duan, Yuanhan Zhang, Bo Li, Songyang Zhang, Wangbo Zhao, Yike Yuan, Jiaqi Wang, Conghui He, Ziwei Liu, et al. Mmbench: Is your multi-modal model an all-around player? arXiv preprint arXiv:2307.06281, 2023.

[33] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In ICLR, 2017.

[34] Junhua Mao, Jonathan Huang, Alexander Toshev, Oana Camburu, Alan L Yuille, and Kevin Murphy. Generation and comprehension of unambiguous object descriptions. In CVPR, 2016.

[35] Kenneth Marino, Mohammad Rastegari, Ali Farhadi, and Roozbeh Mottaghi. OK-VQA: A visual question answering benchmark requiring external knowledge. In CVPR, 2019.

[36] Chandler May, Alex Wang, Shikha Bordia, Samuel R Bowman, and Rachel Rudinger. On measuring social biases in sentence encoders. In NAACL, 2019.

[37] Microsoft. newbing, 2023.

[38] Anand Mishra, Shashank Shekhar, Ajeet Kumar Singh, and Anirban Chakraborty. OCR-VQA: Visual question answering by reading text in images. In ICDAR, 2019.

[39] Norman Mu, Alexander Kirillov, David Wagner, and Saining Xie. Slip: Self-supervision meets language-image pre-training. In ECCV, 2022.

[40] OpenAI. GPT-4V(ision) System Card, 2023.

[41] OpenAI. Gpt-4 technical report, 2023.

[42] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. DINOv2: Learning robust visual features without supervision. arXiv preprint arXiv:2304.07193, 2023.

[43] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In ICML, 2021.

[44] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. JMLR, 2020.

[45] Tal Ridnik, Emanuel Ben-Baruch, Asaf Noy, and Lihi Zelnik-Manor. Imagenet-21k pretraining for the masses. In NeurIPS, 2021.

[46] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. In CVPR, 2022.

[47] Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, et al. Imagenet large scale visual recognition challenge. IJCV, 2015.

[48] Christoph Schuhmann, Romain Beaumont, Richard Vencu, Cade Gordon, Ross Wightman, Mehdi Cherti, Theo Coombes, Aarush Katta, Clayton Mullis, Mitchell Wortsman, et al. LAION-5B: An open large-scale dataset for training next generation image-text models. In NeurIPS, 2022.

[49] Dustin Schwenk, Apoorv Khandelwal, Christopher Clark, Kenneth Marino, and Roozbeh Mottaghi. A-OKVQA: A benchmark for visual question answering using world knowledge. In ECCV, 2022.

[50] Piyush Sharma, Nan Ding, Sebastian Goodman, and Radu Soricut. Conceptual captions: A cleaned, hypernymed, image alt-text dataset for automatic image captioning. In ACL, 2018.

[51] Oleksii Sidorov, Ronghang Hu, Marcus Rohrbach, and Amanpreet Singh. Textcaps: a dataset for image captioning with reading comprehension. In ECCV, 2020.

[52] Amanpreet Singh, Vivek Natarajan, Meet Shah, Yu Jiang, Xinlei Chen, Dhruv Batra, Devi Parikh, and Marcus Rohrbach. Towards VQA models that can read. In CVPR, 2019.

[53] Mannat Singh, Quentin Duval, Kalyan Vasudev Alwala, Haoqi Fan, Vaibhav Aggarwal, Aaron Adcock, Armand Joulin, Piotr Dollár, Christoph Feichtenhofer, Ross Girshick, et al. The effectiveness of MAE pre-pretraining for billion-scale pretraining. In ICCV, 2023.

[54] Quan Sun, Yuxin Fang, Ledell Wu, Xinlong Wang, and Yue Cao. EVA-CLIP: Improved training techniques for clip at scale. arXiv preprint arXiv:2303.15389, 2023.

[55] Tony Sun, Andrew Gaut, Shirlyn Tang, Yuxin Huang, Mai ElSherief, Jieyu Zhao, Diba Mirza, Elizabeth Belding, Kai-Wei Chang, and William Yang Wang. Mitigating gender bias in natural language processing: Literature review. In ACL, 2019.

[56] Tristan Thrush, Ryan Jiang, Max Bartolo, Amanpreet Singh, Adina Williams, Douwe Kiela, and Candace Ross. Winoground: Probing vision and language

models for visio-linguistic compositionality. In CVPR, 2022.

[57] Shengbang Tong, Erik Jones, and Jacob Steinhardt. Mass-producing failures of multimodal systems with language models. In NeurIPS, 2023.

[58] Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, et al. LLaMA: Open and efficient foundation language models. arXiv preprint arXiv:2302.13971, 2023.

[59] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale, et al. LLaMA 2: Open foundation and fine-tuned chat models. 2023.

[60] Michael Tschannen, Manoj Kumar, Andreas Steiner, Xiaohua Zhai, Neil Houlsby, and Lucas Beyer. Image captioners are scalable vision learners too. NeurIPS, 2023.

[61] Kirill Vishniakov, Zhiqiang Shen, and Zhuang Liu. Convnet vs transformer, supervised vs clip: Beyond imagenet accuracy, 2024.

[62] Hu Xu, Saining Xie, Xiaoqing Ellen Tan, Po-Yao Huang, Russell Howes, Vasu Sharma, Shang-Wen Li, Gargi Ghosh, Luke Zettlemoyer, and Christoph Feichtenhofer. Demystifying CLIP data. arXiv preprint arXiv:2309.16671, 2023.

[63] Zhengyuan Yang, Linjie Li, Kevin Lin, Jianfeng Wang, Chung-Ching Lin, Zicheng Liu, and Lijuan Wang. The Dawn of LMMs: Preliminary Explorations with GPT-4V (ision). arXiv preprint arXiv:2309.17421, 2023.

[64] Weihao Yu, Zhengyuan Yang, Linjie Li, Jianfeng Wang, Kevin Lin, Zicheng Liu, Xinchao Wang, and Lijuan Wang. MM-Vet: Evaluating large multimodal models for integrated capabilities. arXiv preprint arXiv:2308.02490, 2023.

[65] Mert Yuksekgonul, Federico Bianchi, Pratyusha Kalluri, Dan Jurafsky, and James Zou. When and why vision-language models behave like bags-of-words, and what to do about it? In ICLR, 2022.

[66] Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training. In ICCV, 2023.

[67] Yuexiang Zhai, Shengbang Tong, Xiao Li, Mu Cai, Qing Qu, Yong Jae Lee, and Yi Ma. Investigating the catastrophic forgetting in multimodal large language models. arXiv preprint arXiv:2309.10313, 2023.

[68] Renrui Zhang, Jiaming Han, Aojun Zhou, Xiangfei Hu, Shilin Yan, Pan Lu, Hongsheng Li, Peng Gao, and Yu Qiao. Llama-adapter: Efficient fine-tuning of language models with zero-init attention. arXiv preprint arXiv:2303.16199, 2023.

[69] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric. P Xing, Hao Zhang, Joseph E. Gonzalez, and Ion Stoica. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena, 2023.

[70] Jinghao Zhou, Chen Wei, Huiyu Wang, Wei Shen, Cihang Xie, Alan Yuille, and Tao Kong. iBOT: Image BERT pre-training with online tokenizer. In ICLR, 2021.

[71] Deyao Zhu, Jun Chen, Xiaoqian Shen, Xiang Li, and Mohamed Elhoseiny. MiniGPT-4: Enhancing vision-language understanding with advanced large language models. arXiv preprint arXiv:2304.10592, 2023.

# A. 实验细节

**超参数。** 在这项工作中，我们采用与 LLaVA [31] 和 LLaVA-1.5 [30] 相同的一组超参数。我们在 LLaVA 实验中使用 Vicuna-13b-v1.3 [69]，在 LLaVA-1.5 实验中使用 Vicuna-13b-v1.5 [69]。我们在表 4 中展示了 LLaVA 和 LLaVA-1.5 实验的训练超参数。所有实验均使用最多 8 个 Nvidia A100 GPU 进行。

| Hyperparameter | LLaVA | | LLaVA-1.5 | |
|---|---|---|---|---|
| | Stage 1 | Stage 2 | Stage 1 | Stage 2 |
| batch size | 128 | 128 | 256 | 128 |
| lr | 1e-3 | 2e-5 | 2e-3 | 2e-5 |
| lr schedule decay | cosine | cosine | cosine | cosine |
| lr warmup ratio | 0.03 | 0.03 | 0.03 | 0.03 |
| weight decay | 0 | 0 | 0 | 0 |
| epoch | 1 | 3 | 1 | 1 |
| optimizer | AdamW [33] | | | |
| DeepSpeed stage | 2 | 3 | 2 | 3 |

Table 4. LLaVA 和 LLaVA-1.5 的 MoF 训练超参数。

**预训练数据集。** 我们为 LLaVA 和 LLaVA-1.5 实验使用相同的数据集。对于 LLaVA 实验，阶段 1 使用 CC595k [50]，阶段 2 使用 LLaVA 158k [31] 指令数据；对于 LLaVA-1.5 实验，阶段 1 使用 CC595k [50]，阶段 2 使用 Liu et al. [30] 提出的 DataMix 665k [1, 15, 21, 23, 24, 31, 34, 35, 38, 49, 51] 数据。

# B. MMVP 基准测试

我们提供了更多关于 MMVP 基准测试的细节。

## B.1. 评估 SOTA 模型的详细信息

我们在 2023 年 10 月和 11 月通过 ChatGPT 访问了 GPT-4V。我们还在 2023 年 12 月通过 Vertex AI API 评估了 Gemini-Pro。我们使用 InstructBLIP 的官方检查点 [8]。我们通过它们的游乐场访问 mini-GPT4 [71]，[1]LLaVA 和 LLaVA-1.5 [31]。我们在 2023 年 9 月和 10 月使用官方网站测试了 Bard [13]。此外，我们在 2023 年 9 月通过新 Bing 聊天创意模式测试了新 Bing [37] 和 GPT-4V [40]。

## B.2. MMVP 基准测试中的问题

我们在图 10、 11、 12的末尾展示了更多的 MMVP 示例。

## B.3. 消融研究

为了进一步验证 MLLMs 在 MMVP 中出现错误是由于其视觉定位能力不足而不是语言模型中的幻觉现象 [20]。我们在 MMVP 中的 VQA 问题和选项的格式及表示上进行了额外的消融实验。我们选择 GPT-4V 进行这些实验，因为它目前是最好的模型。

[1]为了规避 mini-GPT4 的回答幻觉问题，我们将问题前缀为 “请选择一个选项来回答下面的问题，无需解释：”

| | LLaVA-1.5 | InstructBLIP | Bard | Gemini | GPT-4 |
|---|---|---|---|---|---|
| Correlation | 0.87 | 0.71 | 0.79 | 0.72 | 0.31 |

Table 5. CLIP 模型与 MLLMs 之间的皮尔逊相关系数。明确使用基于 CLIP 的模型的开源模型以 灰色 高亮显示。

**交换选项** 第一个实验是在 MMVP 基准测试中交换两个选项。例如，我们将问题从 “蝴蝶的翅膀更接近打开还是关闭？ (a) 打开 (b) 关闭” 改为 “蝴蝶的翅膀更接近打开还是关闭？ (a) 关闭 (b) 打开”。

实证研究表明，在我们的研究中，GPT-4V 在选项交换上的准确率为 40.3%，而原始准确率是 38.7%。我们观察到一些问题的答案有所不同，但大多数答案保持不变。这进一步表明视觉能力的问题在于视觉编码器而非对齐或 LLM。

## B.4. 消融研究

为了进一步验证 MLLMs 在 MMVP 中出现错误是由于其视觉定位能力不足而不是语言模型中的幻觉现象 [20]。我们在 MMVP 中的 VQA 问题和选项的格式及表示上进行了额外的消融实验。我们选择 GPT-4V 进行这些实验，因为它目前是最好的模型。

**交换选项** 第一个实验是在 MMVP 基准测试中交换两个选项。例如，我们将问题从 “蝴蝶的翅膀更接近打开还是关闭？ (a) 打开 (b) 关闭” 改为 “蝴蝶的翅膀更接近打开还是关闭？ (a) 关闭 (b) 打开”。

实证研究表明，在我们的研究中，GPT-4V 在选项交换上的准确率为 40.3%，而原始准确率是 38.7%。我们观察到一些问题的答案有所不同，但大多数答案保持不变。这进一步表明视觉能力的问题在于视觉编码器而非对齐或 LLM。

**更改选项中的符号** 我们进行了一项消融研究以评估改变符号的影响。例如，我们将 “(a) 关闭 (b) 打开” 改为 “(1) 关闭 (2) 打开”。结果与原始发现相当，达到了 37.3% 的表现，接近原来的 38.7%。该研究表明，MLLMs 的核心挑战在于其固有的视觉能力不足，而不是语言模型中的幻觉。

## B.5. 人类研究细节

在这项研究中，我们邀请了四位参与者自愿参加我们的研究。一个用于标注的例子用户界面如图 8所示。我们收集他们的回答并计算平均分作为人类水平的表现。

# C. CLIP-MLLM 失效相关性

**CLIP 和 MLLM 模型之间的相关性。** 我们计算了 CLIP 模型与 MLLMs 之间的皮尔逊相关系数，并在表 5 中展示了结果。值得注意的是，两个开源模型——LLaVA 和 InstructBLIP——表现出非常高的皮尔逊相关系数，超过 0.7。这一发现表明，CLIP 模型所犯错误与 MLLMs 所犯错误之间存在很强的相关性。Bard 也显示出非常高相关性。这表明一些最先进的闭源模型同样受到 CLIP 模型视觉限制的影响。

**ImageNet-1k 与 MMVP 性能之间的相关性。** 我们在图 9中绘制了 ImageNet-1k 零样本准确率与 MMVP-VLM

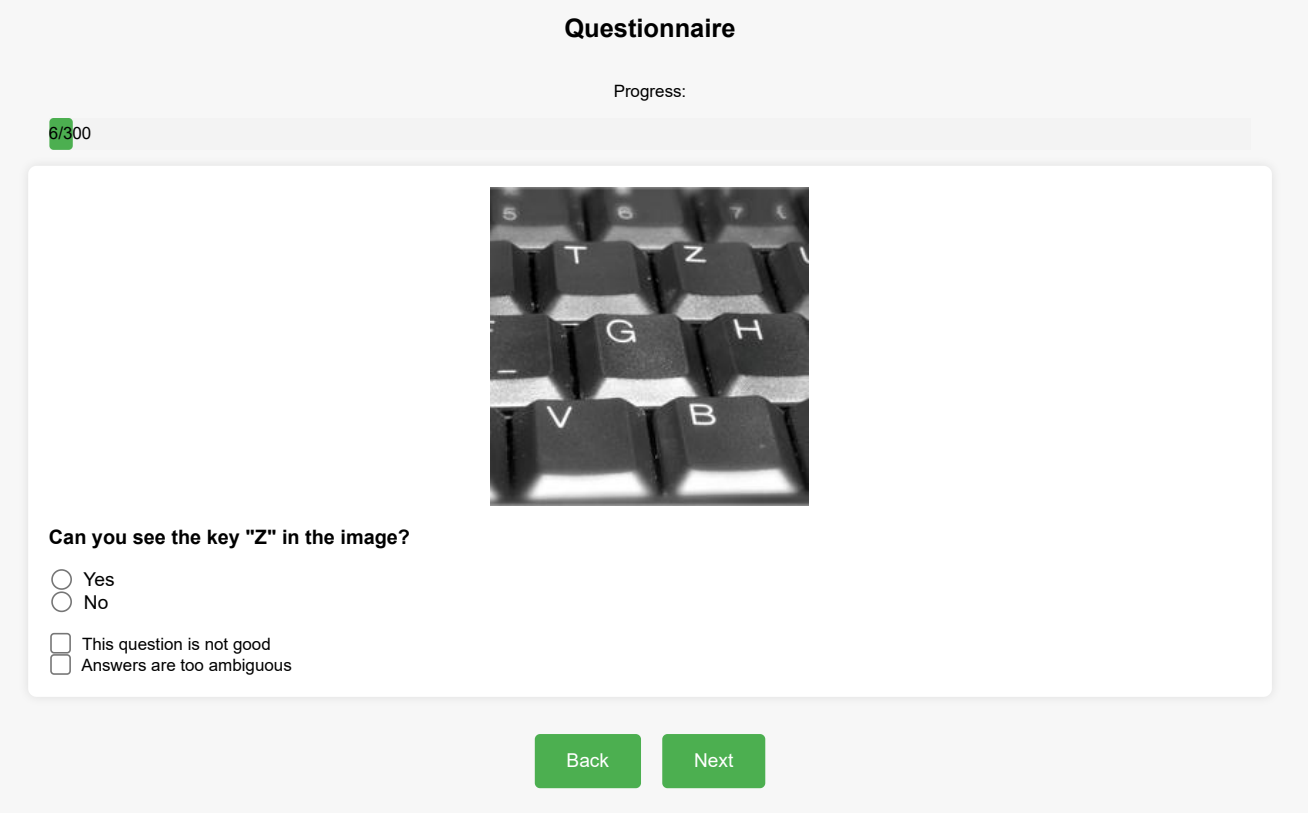



Figure 8. **用户研究界面示例。**用户研究中的问题被随机打乱以避免任何潜在偏见。用户选择 VQA 问题的答案以及对 VQA 问题的潜在关注点。

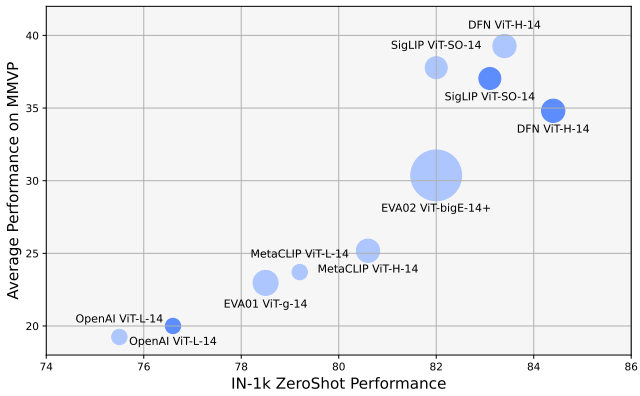



Figure 9. ImageNet-1k **零样本与** MMVP-VLM **平均值的相关性。**每个气泡的面积对应于模型的参数数量。较高的 ImageNet-1k 零样本性能并不必然意味着在 MMVP-VLM 上的表现更好。

平均性能的关系图。对于那些 ImageNet-1k 零样本准确率低于 80 的模型来说，更高的零样本准确率往往意味着更好的 MMVP 性能。然而，在具有更优 ImageNet-1k 零样本性能的模型中，这一趋势并不一定适用于 MMVP-VLM 准确率。这种区别突显了 MMVP-VLM 作为评估指标的价值，它探究的是诸如方向等视觉模式——这些方面对下游任务至关重要，并超越了单独由 ImageNet 准确率所能捕捉到的信息。

## D. CLIP 面临的视觉模式挑战

在这里，我们提供了对所有基于 CLIP 的模型构成挑战的完整视觉模式描述。

- **方向和方位**：关于某物面向或移动的方向的问题，例如狗或鸭子面向哪个方向，或者校车的朝向。
- **特定特征的存在与否**：专注于图像中存在的某些元素或特征是否存在或不存在的问题。
- **状态和条件**：涉及对象的状态或条件的问题，例如旗帜是否在风中飘扬，地面是否潮湿。
- **数量和计数**：关于图像中存在多少个物体或特征的问题。
- **位置和关系上下文**：这一方面指的是模型理解图像中对象或元素之间的位置和关系及其周围环境的能力。
- **颜色和外观**：关于某些对象或元素的颜色的问题。
- **结构和物理特性**：这一类别涉及模型识别和分析图像中对象的物理属性和结构特征的能力。
- **文字**：与图像中存在的文字或符号相关的问题。
- **视角和透视**：关于照片拍摄角度的问题。

## E. 更多基准测试结果

### E.1. 不同的仅视觉主干网络

在这里，我们进行额外的实验来研究涉及 MAE [18] 或 MoCoV3 [17] 的 MoF，而不是 DINOv2；见表 6。在表 6中，我们观察到使用 MAE/MoCov3 时，在视觉定位能力上有一致的提升，如 MMVP 和 POPE 基准所示。

| method | SSL Model | res | #tokens | MMVP | POPE |
|---|---|---|---|---|---|
| LLaVA$^{1.5}$ | None | $336^2$ | 576 | 24.7 | 85.9 |
| LLaVA$^{1.5}$ + I-MoF | MoCov3 | $224^2$ | 512 | 26.7 (+2.0) | 86.1 |
| LLaVA$^{1.5}$ + I-MoF | MAE | $224^2$ | 512 | 27.3 (+2.6) | 86.1 |
| LLaVA$^{1.5}$ + I-MoF | DINOv2 | $224^2$ | 512 | 28.0 (+3.3) | 86.3 |

Table 6. 不同仅视觉自监督模型的交错 MoF 结果

### E.2. 扩展到更大分辨率

我们对交错 MoF 进行了额外的实验，进一步将分辨率提升至 336，并在更多的基准测试上进行评估。表 7总结的结果显示，交错 MoF 在大多数基准测试上实现了可比表现，并在专注于视觉定位的基准测试上表现出改进。我们也观察到，MMVP 对模型的视觉能力更为敏感，强调了我们的基准测试在评估视觉技能方面的重要性。

| method | res | #tokens | MMVP | $LLV^B$ | $LLV^W$ | MMB | $VQA^T$ | POPE | $VQA^{V2}$ | MM-V |
|---|---|---|---|---|---|---|---|---|---|---|
| $LLaVA^{1.5}$ | $336^2$ | 576 | 24.7 | 84.7 | 70.7 | 67.7 | 61.3 | 85.9 | 80.0 | 35.4 |
| $LLaVA^{1.5}$ + I-MoF | $224^2$ | 512 | 28.0 | 82.7 | 73.3 | 61.6 | 55.3 | 86.3 | 77.3 | 33.5 |
| $LLaVA^{1.5}$ + I-MoF | $336^2$ | 1152 | 31.3 | 81.8 | 73.3 | 65.4 | 58.7 | 86.7 | 79.3 | 34.6 |

Table 7. **与 LLaVA-1.5 在另外 6 个基准测试上的比较**. 交错 MoF LLaVA-1.5 在大多数基准测试上达到了与原始方法相当的表现，并且在评估视觉定位的基准测试上有所改进。由于空间限制，基准测试名称进行了缩写。$LLV^B$：LLaVA 基准测试 [31]; $LLV^W$：LLaVA-In-the-Wild [30]; MMB：MMBench [32]; $VQA^T$：TextVQA[52]; POPE：POPE [27]; $VQA^{V2}$：VQA-v2 [15]; MM-V：MM-Vet [64].

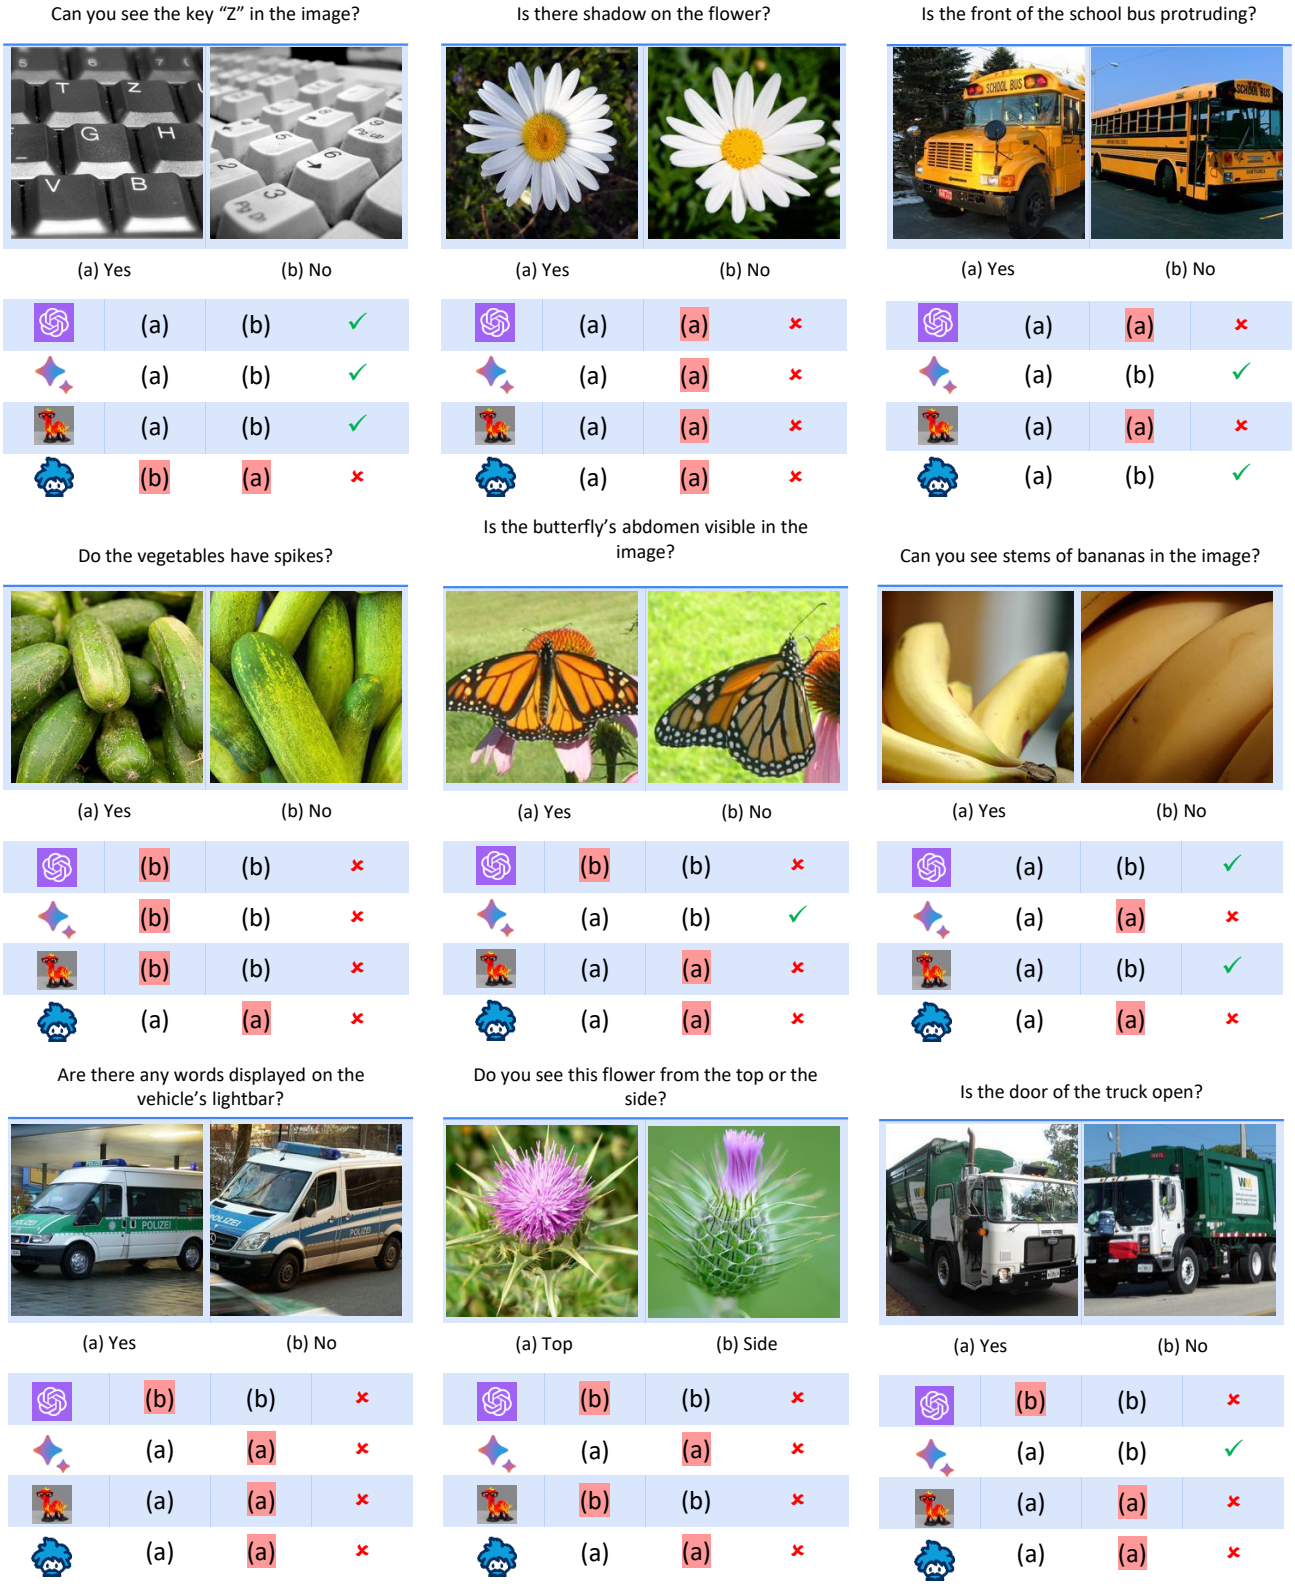



Figure 10. MMVP **基准中的更多问题示例（第一部分）。**

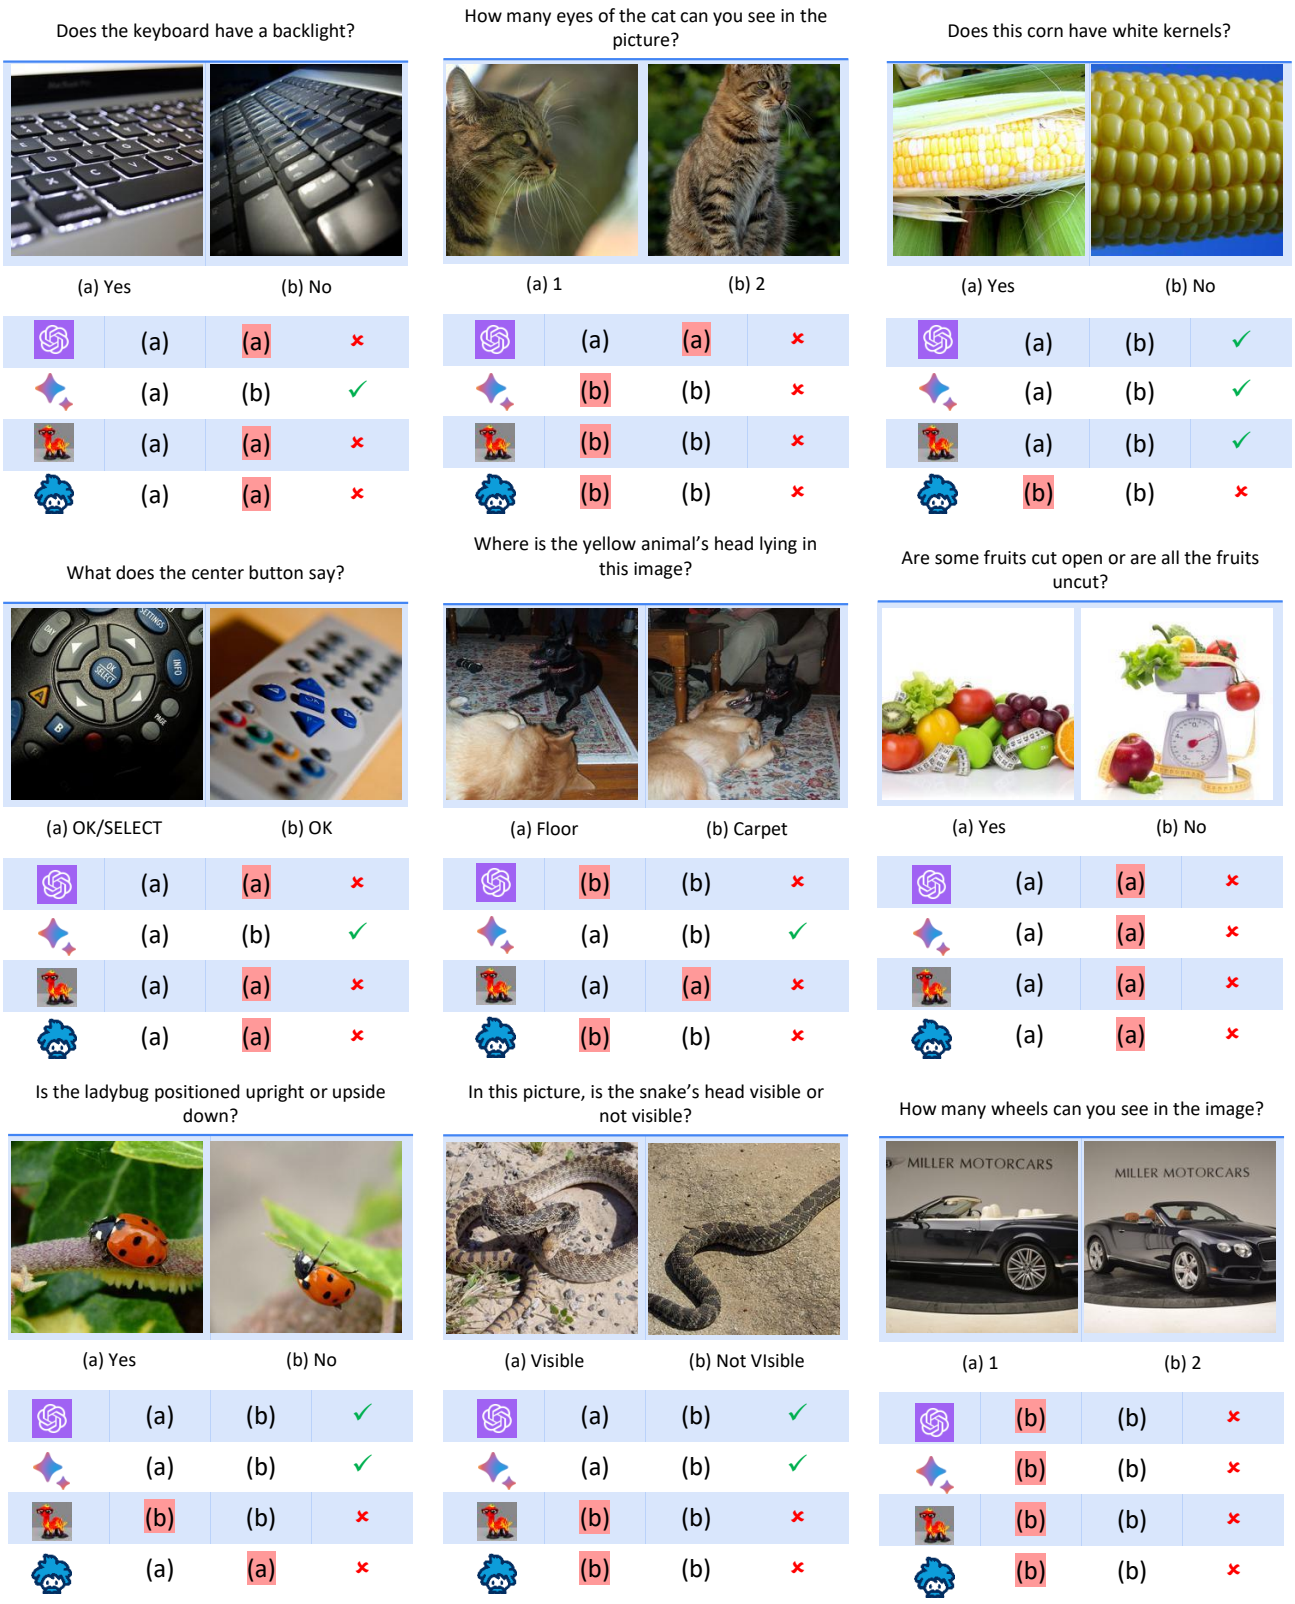



Figure 11. MMVP **基准中的更多问题示例（第二部分）。**

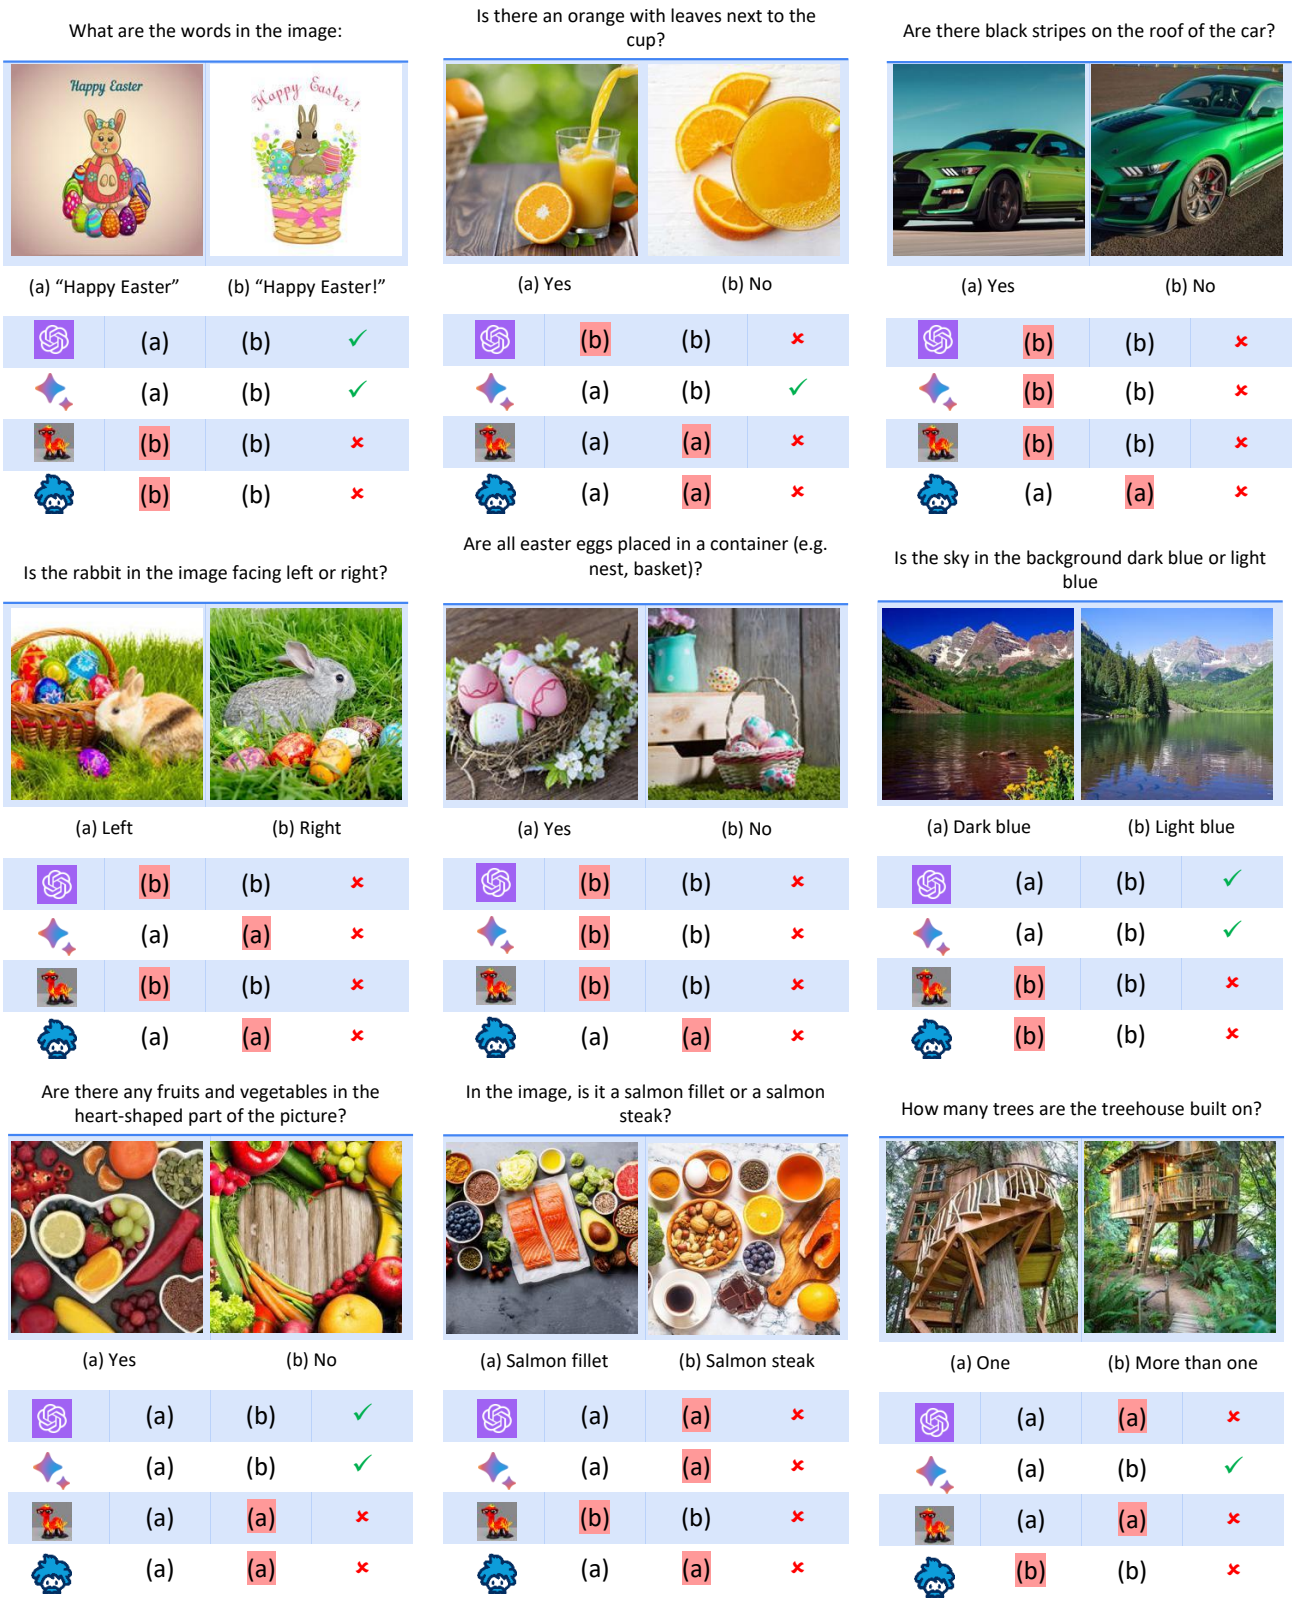



Figure 12. MMVP **基准中的更多问题示例（第三部分）。**